

アトラクタニューラルネットワークモデルの数理解析と その神経心理学への応用

浅 川 伸 一

東京女子大学

Mathematical consideration of attractor neural network model and
Its application to neuropsychology

Shin-ichi ASAKAWA

Tokyo Woman's Christian University

Among models in cognitive science, the attractor neural network (ANN) model (for example, Rogers et al., 2004; Perry, 1999) can be regarded as a practical one. However, the reason why this model is adopted is not clear. To investigate why the ANN was employed is worth-while. Mathematical consideration revealed that there is a necessary and sufficient condition for the ANN to reach stable equilibrium. However, even in the case of unstable equilibrium, the ANN can reach a solution without attractors. Because the behavior of the ANN can be described by differential equations, it is important for the ANN to have a negative real part of the maximum eigenvalue of coefficient matrix. In order to confirm this, computer simulations were conducted. The results revealed that the existence of stable equilibrium depends on the data set. Further implications of this analysis in cognitive neuropsychology were also discussed. According to the method discussed in this study, brain damage can be formulated mathematically. This kind of approach might provide new insight to this area.

Key words: Attractor Neural Network, differential equations, eigen values, stable equilibrium, brain damage

キーワード: アトラクタニューラルネットワーク, 微分方程式系, 固有値, 平衡点, 脳損傷

は じ め に

「アトラクタニューラルネットワーク」(以降 ANN と略記する)という用語は, 一般的には Hopfield and Tank (1985) によって提案された一般的なクラスのニューラルネットワークモデルを指す場合が多い。ANN は, また, Hinton and Shallice (1991); Plaut and Shallice (1993) によって提案された階層型のネットワークを指すこともある。本稿では, 後者のタイプの ANN を取り上げた。このタイプのネットワークは, 出力層とクリーンアップ層との間に相互に結合があり, さらに層内の各ユニットに対しても相互に結合がある。図 1 では, 層内の結合は書かれていない。数学的な理由から, この種のネットワークもホッ

プフィールドタイプのネットワークも ANN と同じ用語で語られている。

ANN は, 神経心理学的データを記述するために開発された (Rumelhart, McClelland, & the PDP research Group, 1986; Hinton & Shallice, 1991)。それゆえ, ANN は, 神経心理学と認知モデルとの橋渡しをする役割を担っているとも言える。神経心理学的研究は, 心理学的モデルの構築に重要な示唆を与えてくれる。そこには, 言語, 記憶, 思考, 認知, など多くの分野が含まれている。脳画像研究と並んで, 神経心理学的証拠は脳と認知とのモデルを構築する際に, 制約を課すことになり, 今日これらのデータを無視して心理学的モデルを提案することは, 得策ではないだろう。

本稿は, 5つの部分から成る。(1) まず, Hinton and Shallice (1991), Plaut and Shallice (1993)

によって導入された ANN を簡単に紹介する。次に、(2) ANN に関する数学的な定式化がなされる。ANN の数学的な性質については、これまで考慮されてきたとは言いがたい。(3) 若干の数値実験を紹介し、その結果と上述の数学的考察との関係が議論される。(4) ANN の可能性についての議論が行われ、(5) 最後に、結論が述べられる。

アトラクタニューラルネットワークモデル

Plaut, McClelland, and Seidenberg (1995) と Plaut (1996) は、ANN を導入し、失読症患者の単語読字時の意味性の誤りや、視覚性の誤り、両者の混交した誤りについて検討を加えた。ニューロンに模した処理ユニットで構成される多次元空間において、ANN は適切なメモリ項目を検索可能である。換言すれば、ANN に適当な初期値が与えられた時、各処理ユニットの活性値は、状態空間を遷移し、“アトラクタ”と呼ばれる状態に吸引されることがある。各メモリ項目ごとに対応するアトラクタが形成されると考えられてきた。与えられる初期値が異なれば、ANN は、異なる“ポイントアトラクタ”に吸引されることになる。すなわち、この場合、アトラクタの“流域”が異なると考えられている。しかし、ここで素朴な疑問が生じる。ANN はなぜ、他の種類のアトラクタが形成されないのだろうか。リミットサイクル、トーラス、ストレンジアトラクタ、カオスなどに収束しない理由は存在するのであろうか。ANN の収束可能性は保証されているのであろうか。本稿の目的は、ANN の性質を調べ、この疑問に答

えることである。

一般にニューラルネットワークモデルにおいては、各処理ユニットは相互に結合されている。各ユニット間の活性値の相互作用によってシステムの状態が定まり、ANN においてはそれがアトラクタへの“吸引可能性”となる。例えば、単音節単語の発音は、各単語ごとに対応する流域を持っているとされる (Harm & Seidenberg, 1999; Plaut et al., 1996; Devlin et al., 1998; Seidenberg et al., 1996; Seidenberg & McClelland, 1989; Patterson, Seidenberg, & McClelland, 1990; Seidenberg et al., 1994; Seidenberg & McClelland, 1989; Seidenberg, 1997)。ANN に小さな雑音や摂動が加わった場合でも、システムの状態が流域内に留まっているのであれば、ANN はノイズや摂動に対して耐性を示す。さらに、ANN が損傷を受けると、アトラクタと流域の位置、形態、大きさなどが変容し、誤ったアトラクタに吸引されるようになることが起こりうる。あるいは、正しくはあっても、そのアトラクタに吸引されるまでに時間がかかってしまうようになったりする (図 2)。これが、ニューラルネットワーク的な脳損傷の説明である。次節では、このような ANN の振る舞いを数学的に記述することを試みる。




図 1 The ANN, Hinton and Shallice (1991); Plaut and Shallice (1993) employed. Input, hidden, output, and cleanup layers were introduced.




図 2 Transformation of the basin of an attractor network by damage

数学的記述

出力層の素子数が 1 であり、クリーンアップ層の素子数も 1 の場合を考えよう。このシステムの

挙動は、2次元の相図として表現することができ
る2。各素子の出力関数は、シグモイド関数であ
ることが多い。この関数は以下のとおりである。

$$f(x) = \frac{1}{1 + \exp(-\alpha x)}, \quad (1)$$

ここで、 α はシグモイド関数の傾きを決めるパラ
メータである $\alpha > 0$ 。しかし、このパラメータ α
の影響を調べた研究は少ないようである。本節で
後に述べるように、ANNの挙動は線形微分方程
式系として定式化できる。ANNの解の軌跡が原
点付近にあれば、シグモイド関数は線形関数とし
て近似可能である（図3参照）。ここで、パラ
メータ α に関する疑問が生じる。パラメータ α
が大きければ、それだけシグモイド関数の傾きは
険しくなる。 $\alpha \rightarrow \infty$ の極限では、

$$\lim_{\alpha \rightarrow \infty} f(x) = \begin{cases} 1 & \text{if } 0 < x \\ 0 & \text{otherwise} \end{cases} \quad (2)$$

となる。このとき、シグモイド関数は、ステップ
関数となる。この関数の値域は（式1） $\{x | 0 \leq f(x) \leq 1\}$ である。 x はこの素子への全入力
を意味する。 x は以下のように表現される $x = \sum_i w_i y_i$ 、ここで
 w_i は結合係数である。 w_i は結合の強さを表し、 θ
はしきい値である $\{\theta | -\infty \leq \theta \leq \infty\}$ 。 y_i は、 x に信
号を送っている i 番目の素子であり、総和 \sum はす
べての y について計算される。特定の y_i と x との
間に結合がなければ、 w_i は0となる。行列 W を
結合係数で構成されるものとしよう。




図3 Sigmoid curves under 3 values of α

$$W = \begin{pmatrix} w_{11} & w_{12} & \cdots & w_{1n} \\ w_{21} & w_{22} & \cdots & w_{2n} \\ \vdots & \vdots & \ddots & \vdots \\ w_{n1} & w_{n2} & \cdots & w_{nn} \end{pmatrix}, \quad (3)$$

ここで、 w_{ij} は素子 j から i の結合係数を表す。 w_{ii}
は、自己フィードバック結合である。添字 i と j
とは、出力層、クリーンアップ層の素子間の結合
である（相互結合や層内結合も含む）。この行列
を用いて、ANNの振る舞いは、微分方程式系と
して次のように記述できる：

$$\frac{dx(\tau)}{d\tau} = -x(\tau) + \phi(Wy(\tau) - I), \quad (4)$$

ここで τ は、出力層とクリーンアップ層との間の
繰り返し回数を表す。 ϕ は、行列 W の各要素に
対してシグモイド関数を適用する演算子としよう。
よく知られているとおり、各層における各素子の
しきい値を表現するために、絶えず1を出力する
仮想的な素子を用意し、そこからの結合係数とし
てしきい値からの影響を表現することができる。
形式的には、そのようにすることで、 W を、1行
増やすことで新たにしきい値を表現できる。この
ようにして、一般性を失うことなく、しきい値を
 I を W に含めることができる。以後、1行増加さ
せた W を改めて W とする。こうすることによっ
て式（3）の W で張られる空間の原点が移動する。
このとき、

$$\frac{dx(\tau)}{d\tau} = -x(\tau) + \phi(Wy(\tau)), \quad (5)$$

となる。先述のとおり、シグモイド関数は原点近
傍において、線形関数で近似できるので、以下の
ような線形微分方程式系を得る。

$$\frac{dx(\tau)}{d\tau} = -x(\tau) + Wy(\tau), \quad (6)$$

この式（6）は、解析的に解くことができ、

$$x(\tau) = x_0 e^{W(\tau - \tau_0)}. \quad (7)$$

がその解となる。

ここで、空間 Y を $2n$ 個の小空間に分割する場
合を考える。

$$\begin{aligned}
& Y(111\cdots 11) \\
& Y(111\cdots 10) \\
& \vdots \\
& Y(p_1 p_2 p_3 \cdots p_{n-1} p_n) \\
& \vdots \\
& Y(000\cdots 00)
\end{aligned} \tag{8}$$

$Y(111\cdots 11)$ は、すべての領域 y_1, y_2, \dots, y_n が正である空間である。The $Y(111\cdots 10)$ は、 y_1, y_2, \dots, y_{n-1} の領域が正であり、 y_n だけが負である領域である。 $Y(000\cdots 00)$ はすべての領域が負となる領域である。 p_1, p_2, \dots, p_n は、1 あるいは 0 のいずれかの値をとる。この分割された領域内においては、状態方程式は、線形関数となりリプシッツの条件 (Lipschitz's condition (9) 式) が成り立つ。

$$|f(y_1) - f(y_2)| \leq N w_{\max} |y_1 - y_2|, \tag{9}$$

ここで、 w_{\max} は、行列 W の要素 w_{ij} 中の最大値を表す。ここで、微分方程式系の平衡点を $y^*(p_1 p_2 \dots p_n)$ 、とすると、

$$W y^*(p_1 p_2 \dots p_n) = x. \tag{10}$$

が得られる。 $|W| \neq 0$ ならば以下の式を得る。

$$y^*(p_1 p_2 \dots p_n) = W^{-1} x \tag{11}$$

ここで、

$$W^{-1} = \begin{pmatrix} c_{11} & c_{12} & \cdots & c_{1n} \\ c_{21} & c_{22} & \cdots & c_{2n} \\ \vdots & & \ddots & \vdots \\ c_{n1} & c_{n2} & \cdots & c_{nn} \end{pmatrix}, \tag{12}$$

とすれば、

$$y^*(p_1 p_2 \dots p_n) = \sum_{j=1}^n c_{ij} x_j. \tag{13}$$

である。この場合、この系が安定な平衡点を持つための必要十分条件は、固有方程式 (14) 式の最大固有値が負の実部を持つことである。

$$|W - \lambda I| = 0 \tag{14}$$

すなわち、本稿の目的の一つは、任意の ANN において結合係数行列 W の最大固有値が必ず正でない実部を持つかどうかを調べることである。以後、結合係数行列 W の最大固有値の実部を Real

Part of Maximum EigenValue の頭文字をとって RPMEV と略記する。もし RPMEV が負でなければ、厳密には ANN “アトラクタ” ネットワークはアトラクタに収束するとは言えないことになる。この仮説が正しいか否かを検証するためには、学習済みの ANN の結合係数行列の RPMEV を調べてみれば良い。

排他的論理和問題の例と固有値

ANN が排他的論理和問題 (XOR 問題) を解いた時の例とベクター図が図 4 に描かれている。横軸は出力層素子の出力値を、縦軸はクリーンアップ層素子の出力値をそれぞれ表している。図 4 から明らかなように、(0.25, 1.0) 付近にアトラクタが存在する。すなわち、このシステムは初期値にかかわらず点 (0.25, 1.0) に引き込まれる傾向があると言える。出力しとして (1, 0) が必要な場合には、(1, 0) 付近の値が初期値となり、このシステムは繰り返し計算をせずに即時に出力を返す。具体的には、この場合の結合係数行列 W は、

$$W = \begin{pmatrix} -1.25 & 0.22 \\ 0.25 & 0.04 \end{pmatrix}, \tag{15}$$

であった。この場合特性方程式を $|W - \lambda I|$ を解いて、この式の解の実根が全て負であることが確認できる。すなわち、この解は安定な平衡点を持つ。

ターゲット (教師信号) がバイナリ (0, 1) であり、初期値の出力ベクターの各要素が 0 または 1 に十分近ければ、ANN は、結合係数行列 W がどうであれ、RPMEV がどうであれ、その計算を停止させる。

収束問題

ターゲット信号が排他的論理和問題のようなバイナリ (0, 1) の場合、アトラクタは、図 5 の影をつけた領域内に存在することになるのかも知れない。そうでなければ、システムが解にたどり着くためには、図 6 のように、収束ではなく、発散が必要となるかも知れない。この場合、システムが安定な平衡点を持つ必要はない。この場合には、RPMEV は正であり、不安定な平衡点は “リペラ repeller” と呼ばれる。

以上から、ANN が排他的論理和を解く場合に




図4 Asolution of XOR problem by ANN




図5 Location of attractors in case of binary teacher signals




図6 The case of no attractors, no convergence zones but get solution

は、3つの場合が考えらる。

1. 各入力値と出力値に対応するアトラクタが存在する場合
2. 一方がアトラクタであり、他方はリペラである場合
3. すべての解がリペラである場合

このように、ANNの挙動を分析することが可能である。次節以降では、このような考察が妥当かどうかを検討することとしたい。

初期値問題

本稿で行われたシミュレーションでは、出力層

とクリーンアップ層との素子の初期値は、固定されなかった。もし、初期値を固定してしまうと、出力層ユニットへの入力に対してしきい値と同じ役割を果たすことになるからである。このとき、多数のクリーンアップ層の素子を導入する意味合いが薄れる。繰り返し計算の初期値として、値を固定するのではなく、 $0 \leq x \leq 1$ なる一様乱数を初期値として導入した。しかし、Seidenberg and McClelland (1989), Plaut et al. (1996) などのような先行研究では初期値は固定されていたようである。出力層素子とクリーンアップ層素子の初期値として乱数を導入することによって、多数回の学習を繰り返すことで、近似的に全状態空間での収束を保証することになると考えられる。

ANNに限らず一般にニューラルネットワークモデルにおいては、構築されたシステムは、いわゆる“次元の呪い curse of dimensionality”問題に直面しなければならない。探索すべき空間の次元が上がれば上がるほど、探索すべき領域は指数関数的に広がる。次元の呪いを避けるための一方策として、各事例の訓練時に、出力層とクリーンアップ層の素子の初期値として乱数を導入することは有益であると考えられる。この乱数を初期値として与えるということの意味は、訓練時に結合係数の初期値として乱数を付与するという、一般に用いられているニューラルネットワークの構築方法の一つとは意味が異なることに注意されたい。結合係数の初期値を乱数で初期化することは、そのシステムが探索空間において、初期状態がどの方向に向かうのかを定めるため、乱数によって任意の方向を向かせ、偏向した事前知識から探索を始めることを避けるための意味合いである。この意味での乱数による初期化と、ANNにおいて出力層とクリーンアップ層の初期値を乱数で初期化した、状態空間のすべてにおいて収束を保証するようにすることは、意味が異なる。

数 値 実 験

方 法

全シミュレーションを通して学習係数は0.01に固定された。モーメント法や重み崩壊法などのテクニックは用いられなかった。各素子間の結合係数は、 $-0.1 < x < +0.1$ なる乱数で初期化した。

出力層素子とクリーンアップ層素子との間の繰り返し回数の上限は10回とした。ANNが、学習収束基準（自乗誤差が0.05以下）に達したことをもって学習成立とみなした。各学習エポックにおいて、繰り返し上限回数に達する前に収束した場合には、繰り返し計算を終了し、次の項目の学習に移った。各学習項目の学習順序は、エポック毎にランダム化された。ANNの学習には一般化デルタルール (Rumelhart et al., 1986) が用いられた。上述のとおり、出力層素子とクリーンアップ層素子の初期値は、 $0.0 < x < 1.0$ なる一様乱数でその都度初期化された。

安定性の問題

すでに述べたとおり、特性方程式 (14) 式は、ANNの大域的な挙動を定める。もしRPMEVが負ならば、ANNは安定な平衡点を持つ。ANNが特定の問題において解を得、その結果得られた結合係数行列の固有値が計算できる。表1、表2、及び表3は、負のRPMEVが現れた回数を示している。負のRPMEVの出現回数は、データ毎に、条件毎に変化した。負のRPMEVの出現回数は、隠れ層ユニットの数が増加するに従ってわずかに減少しているように見えるが、統計的には有意ではなかった ($\chi^2=6.94$, $d.f.=4$, $p=0.9993$, 表1)。ここで、ANNは必ずしも安定な平衡点を持つわけではないことが示唆されたことは意味がある。安定な平衡点を持たない場合、ANNは正解にたどり着くために不安定な平衡点を利用していたと考えられる。

対照的に、Hinton and Shallice (1991) のデータは、調べた全条件で、ほとんどの場合、負のRPMEVを持っていたようである (表2)。もちろん、決定論的な結論を導き出すのは難しいが、データ集合の差異がシステムの安定性に関して、重要な相違をもたらすように思われる。しかし

表1 Summary of simulation of Plaut and Shallice (1993) (n=100)

cleanup	hidden		
	30	40	50
1	89	83	68
2	81	77	74
4	73	74	61
8	69	62	61
16	55	62	75

表2 Summary of simulation of Hinton and Shallice (1991) (n=50)

cleanup	hidden		
	30	40	50
1	100	100	100
2	100	100	100
4	100	100	100
8	100	100	100
16	100	100	100

表3 Summary of simulation of Tyler et al. (2000) (n=100)

cleanup	hidden		
	10	20	30
1	88	81	53
2	85	72	44
4	57	43	32
8	8	19	23
16	7	4	14

ながら、これはシミュレーション研究の限界でもある。全パラメータを調べるのは不可能である。中間層、クリーンアップ層の素子数、学習係数、シグモイド関数の傾き、初期値として採用する乱数の範囲、出力層とクリーンアップ層との間の繰り返し数の上限值など、すべてを調べることはできない。実験心理学において、すべての実験条件を調べることができないのと事情は同じである。全パラメータ空間を調べるわけにはいかないので、結論を導き出すためには注意が必要だが、少なくとも Hinton and Shallice (1991) のデータ集合は、安定な平衡点を持つ傾向にあったと言えるかも知れない。

ここで、重要なのは、あらかじめデータ集合を調べただけでは、このような予測が不可能なことである。あくまで計算させてみるしか、方法はない。

次に、表3は、別の結果を示している。表3の結果は、統計学的には有意である ($\chi^2=36.123$ $d.f.=8$ $p=0.0001$)。従って、RPMEV は、データ集合間で顕著な違いを生じたと言うことができる。我々は ANN を使ってシミュレーション研究を行うことができるが、そこには細心の注意が必要となろう。

考 察

上述のシミュレーション結果から、ANN は必ずしも決定論的に安定な平衡点を持つ訳ではないことが明らかとなった。ある場合には、安定な平衡点を持つが、不安定な平衡点を持つ場合も存在する。もし、ANN が負の RPMEV を持ったのなら、学習すべき全項目にアトラクタが存在した可能性が指摘できる。もしそうでなければ、図4と図6のように、リペラであるか、初期状態が図5と図6の斜線の領域に入り、繰り返し計算を必要とせず答えを出すものと解釈できる。リペラであった場合 (図6)、摂動などの影響を受けた場合、システムがどの方向に向かうのかを予測することは困難である。同様に、初期状態が斜線の領域に入る場合に関しても、ANN が解いた解は、初期値と障害耐性にと問題があるものと考えられる。ANN に関する数学的考察は、このような洞察を与えてくれる。このことは、認知神経心理学において、ある学習済の概念なり単語なりカテゴリーなりの脳損傷耐性について、含意を与えることになるかもしれない。もし、システム、あるいは脳がある概念なり項目に対してリペラしか持たないのであれば、脳の障害によって、その概念なり項目は簡単に影響を受け、混乱や概念の消失を招くことになるであろう。

繰り返しになるが、ANN は必ずしもアトラクタを持つとは限らない。それは、学習すべきデータ集合と条件とに依存する。データ集合によっては、安定な平衡点を持つ傾向があるものと、そうでないものがある。このことは、実証的研究、理論的研究の両者に対して同様の重要な意味を持つことになるかもしれない。実証的研究においては、用いる課題間の比較をする際に、RPMEV は重要な役割を果たし、現象をより良く理解する一助となる可能性が指摘できる。

人間やコンピュータの行動の性質を解き明かそうとするシミュレーション研究においては、シミュレーション研究の限界を理解することが重要だと考える。上で述べたシミュレーション実験では、安定な平衡点を持つ場合もあれば、そうでない場合もあった。それ故、ANN が常に安定な解を与えるのか否かを定めることはできない。それ

は、データ集合、用いる素子数、などに依存する。この点において、システムの限界を解明するためには、数学的な考察が重要な役割を果たすことになる。ANN の解析はまさに、この場合に相当すると思われる。

今日まで、なぜ多くの研究者が ANN のこの点に関して注意を払って来なかったのかは、大きな疑問である。ここに示した考察に従えば、ANN は微分方程式系として定式化できるので、その大域的な挙動は、解析的に予測できる。

Hinton and Shallice (1991), Plaut and Shallice (1993), Plaut et al. (1995), そして Plaut (1996) は、神経心理学的症状を記述するためのモデルとして ANN を用いた。一般に、ANN におけるアトラクタとは、記憶中の各項目、単語、概念などに該当すると考えられる。しかしながら、先行研究の結果は、厳密には「アトラクタ」によるものではないのかも知れない。この意味では、「アトラクタニューラルネットワークモデルは必ずしもアトラクタニューラルネットワークではない。」表 2 において、すべての試行で負の RPMEV が観察されたが、正の RPMEV を持つ可能性が排除されたとは限らない。そして、正の RPMEV を持つ場合であって、ANN は課題を解くことが可能である。その場合には、ANN が安定な平衡点を持っていないことについて注意が必要となるであろう。

不安定な平衡点を持つシステムは、損傷を受けると容易に困難を示すようになるであろう。脳損傷の意味をこのような視点から解釈することが可能となるかもしれない。そして、損傷の程度を結合係数行列 W と RPMEV の変化として表現可能となるかも知れない。神経心理学の症例の中には、このような考察が可能な場合が見出される可能性が指摘できよう。脳損傷患者の行動は、結合係数行列の縮退や劣化であり、RPMEV が変化して安定な平衡点が消失したと解釈するなどである。もちろん、現時点ではこのような解釈は単なるスペキュレーションでしかない。しかし、知る限りにおいて、ANN を数学的に解析し、脳損傷の解釈に適用しようとする試みは初めてのものである。このことの意味は強調されるべきだと考えられる。繰り返しになるが、ANN は、必ずしも安定な平衡点を持つとは限らない。

結 論

ANN は、心理学、認知科学を始め多くの関連領域に適用可能である。その中には、言語、思考、記憶、認知、カテゴリー化などが含まれる。しかし、ANN を適用する際には注意が必要である。少なくとも、すべての学習項目を学習した後に得られた、結合係数行列から RPMEV を計算すべきである。なぜなら、その解にアトラクタではなく、リベラが含まれている場合があるからである。換言すれば、システムは安定な平衡点を持つのではなく、不安定な平衡点を持つ可能性が指摘できる。

どのようなニューラルネットワークモデルであれ、すべての素子から成る結合係数は行列として表現できる。そこに、連続的であれ離散的であれ、時間を考慮に入れた場合には、時間に関しての微分方程式系が定義できる。もし、素子の出力関数が微分可能であれば、本稿で示したような線形近似の技法が適用可能な場合が存在する。このような定式化はニューラルネットワークモデルの挙動を理解する助けとなる。本稿ではこのような流れに沿った一例を示した。モデルの適用可能性と示唆とがこのような考察から得られた。ANN は有効な道具である。しかし、その数学的な性質が明らかになった時に、さらに心理学、認知科学、認知神経心理学を始めとする各分野に対して、さらに実用性を増すものと考えられる。Hinton and Shallice (1991) が採用した ANN はほとんど必ず安定な平衡点を持っていた。一方、Tyler et al. (2000) のものはそうではなかった。この差異は、以降考慮する必要がある。高次脳機能をニューラルネットワークモデルを用いて解明しようとする研究者は、RPMEV を考慮すべきだと考える。少なくとも、我々は解の安定性に関してはデータ集合によって、かなり異なることがあることを知るべきである。

謝 辞

本稿をまとめるにあたり、助力を頂いた岩船幸代氏に感謝する。彼女の助力がなければ本稿は完成しなかった。

文 献

- Devlin, J., Gonnerman, L., Andersen, E., & Seidenberg, M. (1998). Category-specific semantic deficits in focal and widespread brain damage: A computational account. *Journal of cognitive neuroscience*, 10(1), 77-94.
- Harm, M. W., & Seidenberg, M. S. (1999). Phonology, reading acquisition, and dyslexia: Insights from connectionist model. *Psychological Review*, 106(3), 491-528.
- Hinton, G. E., & Shallice, T. (1991). Lesioning an attractor network: Investigations of acquired dyslexia. *Psychological Review*, 98(1), 74-95.
- Hopfield, J. J., & Tank, D. W. (1985). Neural computation of decisions in optimization problems. *Biological Cybernetics*, 52, 141-152.
- Patterson, K. E., Seidenberg, M. S., & McClelland, J. L. (1990). Connections and disconnections: Acquired dyslexia in a computational model of reading processes. In R. G. M. Morris (Ed.), *Parallel distributed processing: Implications for psychology and neuroscience* (pp. 131-181). Oxford University Press.
- Perry, C. (1999). Testing a computational account of category-specific deficits. *Journal of Cognitive Neuroscience*, 312-320.
- Plaut, D. (1996). Rereading after damage in connectionist networks: Toward a theory of rehabilitation. *Brain and Language*, 52, 25-82.
- Plaut, D., McClelland, J. L., & Seidenberg, M. S. (1995). Reading exception words and pseudowords: Are two routes really necessary? In J. P. Levy, D. Bairaktaris, J. A. Bullinaria, & P. Cairns (Eds.), *Connectionist models of memory and language* (pp. 145-159). London: University College London Press.
- Plaut, D., McClelland, J. L., Seidenberg, M. S., & Patterson, K. (1996). Understanding normal and impaired word reading: Computational principles in quasi-regular domains. *Psychological Review*, 103, 56-115.
- Plaut, D., & Shallice, T. (1993). Deep dyslexia: A case study of connectionist neuropsychology. *Cognitive Neuropsychology*, 10(5), 377-500.
- Rogers, T. T., Lambon Ralph, M. A., Garrard, P., Bozeat, S., McClelland, J. L., Hodges, J. R., et al. (2004). Structure and deterioration of semantic memory: A neuropsychological and computational investigation. *Psychological Review*, 205-235.
- Rumelhart, D. E., McClelland, J. L., & Group, T. P. R. (Eds.). (1986). *Parallel distributed processing: Explorations in the microstructures of cognition*. Cambridge, MA: MIT Press.
- Seidenberg, M. S. (1997). Language acquisition and use: Learning and applying probabilistic constraints. *Science*, 1599-1603.
- Seidenberg, M. S., Alan, P., Plaut, D., & MacDonald, M. C. (1996). Pseudohomophone effects and models of word recognition. *Journal of Experimental Psychology: Learning, Memory, and Cognition*, 22(1), 48-62.
- Seidenberg, M. S., & McClelland, J. L. (1989). A distributed, developmental model of word recognition and naming. *Psychological Review*, 96(4), 523-568.
- Seidenberg, M. S., Plaut, D., Petersen, A. S., McClelland, J. L., & McRae, K. (1994). Nonword pronunciation and models of word recognition. *Journal of Experimental Psychology: Human Perception and Performance*, 20(6), 1177-1196.
- Tyler, L., Moss, H. E., Durrant-Peatfield, M. R., & Levy, J. P. (2000). Conceptual structure and the structure of concepts: A distributed account of category-specific deficits. *Brain and Language*, 75, 195-231.

— 2013. 4. 11 受理 —